

Trabalho Prático nº 2 – Problema de Otimização

Docentes:
Carlos Pereira
Inês Domingues

Trabalho realizado por:
Diogo Oliveira - a2021146037
Lara Bizarro - 2021 130066

Índice

Introdução.....	4
Descrição da Função, Objetivo de Otimização, Descrição dos Algoritmos.....	5
Análise dos Resultados Obtidos	10
Resultados da Pesquisa Local	10
Resultados do Algoritmo Híbrido	11
Resultados do Algoritmo Híbrido	13
Conclusão.....	15

Índice de Imagens

Figura 1 - Função de Recristalização	5
Figura 2 - Função gera_vizinho	5
Figura 3 - Função calcula_fit	5
Figura 4 - Função init_dados	6
Figura 5 - Função tournament	6
Figura 6 - Função crossover	6
Figura 7 - Função crossover_uniforme	7
Figura 8 - Função mutation	7
Figura 9 - Função mutation_trade	7
Figura 10 - Função eval_individual_penalizado	8
Figura 11 - Função eval_individual_rep	8
Figura 12 - Função gera_vizinho_hibrido	9
Figura 13 - Função recristalizacao_hibrido	9
Figura 14 - Custo Igual	10
Figura 15 - Custo Menor	10
Figura 16 - 1ª Experiência Evolutivo	11
Figura 17 - 2ª Experiência Evolutivo	11
Figura 18 - 3ª Experiência Evolutivo	12
Figura 19 - 1ª Experiência Híbrido	13
Figura 20 - 2ª Experiência Híbrido	13

Introdução

No âmbito da cadeira de Introdução à Inteligência Artificial (IIA), foi pedido para realizar um trabalho para resolver um Problema de Otimização, tendo como objetivo conceber, implementar e testar os métodos que encontrem soluções de custo mínimo.

Este dividiu-se em dois componentes, sendo que uma é o componente de criação/implementação e o outro o componente de realização/ análise dos resultados.

No componente da criação/ implementação foram criadas várias funções para posteriormente serem usadas para os testes. O projeto em si, está dividido em três partes, as funções para o Algoritmo da Pesquisa Local, o Algoritmo Evolutivo e o Algoritmo do Híbrido. Ao nível dos testes, foram realizados pelo menos dez testes para cada variância de valores.

Descrição da Função, Objetivo de Otimização, Descrição dos Algoritmos

No primeiro método, abordámos por usar a função de Recristalização, que recebe como parâmetros um ponteiro da solução, um ponteiro da matriz e os vértices, ao usar variáveis definidas gera soluções a cada iteração e vai substituindo a solução anterior no caso de ser melhor. A função `gera_vizinho`, é usada para otimizar e encontrar a melhor heurística ao longo dos ficheiros.

A função `calcula_fit`, como o próprio nome indica serve para calcular o melhor *fitness* de cada ligação.

A função `init_dados`, é usada para receber os dados dos ficheiros de teste e ir percorrendo estes até chegar ao seu fim.

O objetivo deste primeiro Método é encontrar os menores valores médios com o seu melhor custo associado.

```
custo = calcula_fit(&sol, mat, vert);
int k = 5;
t = tmax;

while(t > tmin)
{
    for(int i = 0; i < k; i++)
    {
        gera_vizinho(&sol, &nova_sol, &vert);
        custo_viz = calcula_fit(&nova_sol, mat, vert);

        if(custo_viz <= custo)
        {
            substitui(&sol, &nova_sol, &vert);
            custo = custo_viz;
        }
        else
        {
            r = rand_B1();
            if(r < exp(-(custo_viz-custo)/t))
            {
                substitui(&sol, &nova_sol, &vert);
                custo = custo_viz;
            }
        }
    }
    t -= fa;
}
```

Figura 1 - Função de Recristalização

```
void gera_vizinho(int a[], int b[], int n)
{
    int i, p1, p2;

    for(i=0; i<n; i++)
        b[i]=a[i];

    do
        p1=random_L_h(min, 0, max, n-1);
    while(b[p1] != 0);

    do
        p2=random_L_h(min, 0, max, n-1);
    while(b[p2] != 1);
    b[p1] = 1;
    b[p2] = 0;
}
```

Figura 2 - Função `gera_vizinho`

```
int calcula_fit(int a[], int **mat, int vert)
{
    int i, j, teste, sum = 0;

    for(i = 0; i < vert; i++) {
        teste = 0;
        if (a[i] == 1)
        {
            for (j = 0; j < vert; j++)
            {
                if (a[j] == 1 && mat[i][j] != 0) {
                    sum += mat[i][j];
                    teste = 1;
                }
            }
            if (teste == 0) {
                return 999999999;
            }
        }
    }
    return sum/2;
}
```

Figura 3 - Função `calcula_fit`

```

p = malloc( sizeof(int)*n);
if(!p)
{
    printf("Erro na alocacao de memoria\n");
    exit(1);
}

for(int i=0; i<n; i++)
{
    p[i] = malloc( sizeof(int)*n);
    if(p[i] == NULL)
    {
        printf("Erro na alocacao de memoria\n");
        exit(1);
    }
    for(int j=0; j<n; j++)
        p[i][j] = 0;
}

for(int i = 0; i<lig; i++)
{
    fscanf(stdin, "%d %d %d", &lin, &col, &custo);
    p[col-1][lin-1] = custo;
    p[col-1][lin-1] = custo;
}

```

Figura 4 - Função init_dados

No segundo método, tivemos uma abordagem um pouco mais complexa, porque era necessário usar dois tipos de funções, onde uma delas sempre que a ligação não era válida continuava até acabar o ficheiro, enquanto a posterior sempre que a ligação não é válida tenta encontrar outras ligações para a anterior tornar se válida.

A função tournament, serve para fazer a seleção entre pares da população do ficheiro compara o fitness de cada um e o melhor é usado para a próxima geração.

```

void tournament(pchrom pop, struct info d, pchrom parents)
{
    int i, x1, x2;

    // Realiza popsize torneios
    for(i=0; i<d.popsize; i++)
    {
        x1 = random_l_h( min: 0, max: d.popsize-1);
        do
        {
            x2 = random_l_h( min: 0, max: d.popsize-1);
            while(x1==x2);
        } while(x1==x2);
        if(pop[x1].fitness > pop[x2].fitness) // Problema
            parents[i]=pop[x1];
        else
            parents[i]=pop[x2];
    }
}

```

Figura 5 - Função tournament

As seguintes foram criadas para serem mudadas, quando fosse para realizar os testes:

- A função crossover serve para trocar os genes entre os pais, para criar ligações diferentes.

```

void crossover(pchrom parents, struct info d, pchrom offspring)
{
    int i, j, point;

    for (i=0; i<d.popsize; i+=2)
    {
        if (rand_01() < d.pr)
        {
            point = random_l_h( min: 0, max: d.numGenes-1);
            for (j=0; j<point; j++)
            {
                offspring[i].p[j] = parents[i].p[j];
                offspring[i+1].p[j] = parents[i+1].p[j];
            }
            for (j=point; j<d.numGenes; j++)
            {
                offspring[i].p[j] = parents[i+1].p[j];
                offspring[i+1].p[j] = parents[i].p[j];
            }
        }
        else
        {
            offspring[i] = parents[i];
            offspring[i+1] = parents[i+1];
        }
    }
}

```

Figura 6 - Função crossover

- A função `crossover_uniforme`, usando o índice dos genes do país, serve para ligações diferentes, graças a usar o índice torna o programa mais otimizado.

```
void crossover_uniforme(pchrom parents, struct info d, pchrom offspring)
{
    int i, j;
    for(i = 0; i < d.popsize; i+=2)
    {
        offspring[i] = parents[i];
        offspring[i+1] = parents[i+1];
        for(j = 0; j < d.numGenes; j++)
        {
            if(parents[i].p[j] != parents[i+1].p[j])
            {
                if(rand_01() < d.pr)
                {
                    offspring[i].p[j] = parents[i+1].p[j];
                    offspring[i+1].p[j] = parents[i].p[j];
                }
            }
        }
    }
}
```

Figura 7 - Função `crossover_uniforme`

- A função `mutation`, realiza uma mutação simples ao inverter aleatoriamente os genes de cada filho.

```
void mutation(pchrom offspring, struct info d)
{
    int i, j;

    for (i=0; i<d.popsize; i++)
        for (j=0; j<d.numGenes; j++)
            if (rand_01() < d.pm)
                offspring[i].p[j] = !offspring[i].p[j];
}
```

Figura 8 - Função `mutation`

- A função `mutation_trade`, efetua uma mutação mais específica, ao trocar o valor dos genes por um e por 0 e assim vice-versa, assim obtém se melhorados resultados.

```
void mutation_trade(pchrom offspring, struct info d)
{
    int i, j;
    for(i = 0; i < d.popsize; i++)
    {
        for(j = 0; j < d.numGenes; j++)
        {
            if(rand_01() < d.pm)
            {
                int v1;
                int v2;

                do {
                    int index = random_l_h(0, d.numGenes - 1);
                    if (offspring[i].p[index] == 1) {
                        v1 = index;
                        break;
                    }
                } while (1);

                do {
                    int index = random_l_h(0, d.numGenes - 1);
                    if (offspring[i].p[index] == 0) {
                        v2 = index;
                        break;
                    }
                } while (1);
                offspring[i].p[v1] = 0;
                offspring[i].p[v2] = 1;
            }
        }
    }
}
```

Figura 9 - Função `mutation_trade`

As seguintes funções são as responsáveis pela avaliação das ligações. A primeira destas a `eval_individual_penalizado`, ao iterar vai recebendo os genes das ligações, no entanto se estas não encontrarem genes iguais a função segue para outros genes, dado isso os resultados usando esta função não são os mais ótimos.

```
int eval_individual_penalizado(int sol[], struct info d, int **mat, int *v)
{
    int i, j;
    int sum = 0, flag = 0;
    int vertice = 0;
    *v = 1;

    for (i = 0; i < d.numGenes; i++) {
        flag = 0;

        if (sol[i] == 1) {
            vertice++;
            for (j = 0; j < d.numGenes; j++) {
                if (sol[j] == 1 && mat[i][j] != 0 && i != j) {
                    sum += mat[i][j];
                    flag = 1;
                }
            }
            if (flag == 0) {
                *v = 0;
            }
        }
    }

    if (vertice != d.capacity) {
        *v = 0;
    }
}
```

Figura 10 - Função `eval_individual_penalizado`

A versão melhorada da função anterior, `eval_individual_rep`, porque ao longo da sua iteração quando encontra genes que não se conectam, começa a procura de genes que correspondam com os anteriores, deste modo, os valores finais são extramente melhores em todos os ficheiros de teste.

```
int eval_individual_rep(int sol[], struct info d, int **mat, int *v)
{
    int i, j, valido;
    int sum = 0, flag = 0;
    int vertice = 0;
    *v = 1;

    for (i = 0; i < d.numGenes; i++)
    {
        flag = 0;

        if (sol[i] == 1)
        {
            vertice++;

            for (j = 0; j < d.numGenes; j++)
            {
                if (sol[j] == 1 && mat[i][j] != 0 && i != j)
                {
                    sum += mat[i][j];
                    flag = 1;
                }
            }
        }
    }
}
```

Figura 11 - Função `eval_individual_rep`

Ao nível do último método, o Híbrido, acaba por combinar os dois últimos métodos supracitada, usando a função `gera_vizinho_hibrido`, copia a solução atual para a variável "solViz" a solução vizinha e depende do valor definido pelo "TrocaVertice" troca o valor do gene, ou seja inverte o valor de zero para 1 e vice-versa.

A função `recristalizacao_hibrido`, uso para cada solução que a função acima devolve, avalia-o usando o `eval_individual_rep` para calcular o valor de fitness e se o valor do vizinho for menor do atual, substitui por essa solução.

```
void gera_vizinho_hibrido(int sol[],int solViz[],int **mat,int nGenes)
{
    int i;
    //copia a solucao para a vizinha
    for(i=0;i<nGenes;i++) {
        solViz[i] = sol[i];
        if (rand_01() < TrocaVertice) {
            i = random_l_h( min: 0, max: nGenes - 1);
            solViz[i] = !solViz[i];
        }
        else {
            for (i = 0; i < nGenes; i++) {
                gera_vizinho( a: sol, b: solViz, n: nGenes);
            }
        }
    }
}
```

Figura 12 - Função `gera_vizinho_hibrido`

```
void recristalizacao_hibrido(pchrom pop,struct info d,int **mat){
    int i,j;
    chrom vizinho;
    for(i=0;i<d.popsize;i++)
    {
        for(j=0;j<d.Ngeneration_h;j++)
        {
            gera_vizinho_hibrido( sol: pop[i].p, solViz: vizinho.p,mat, nGenes: d.numGenes);
            vizinho.fitness=eval_individual_rep( sol: vizinho.p,d,mat, % &vizinho.valido);
            if(vizinho.fitness < pop[i].fitness)
                pop[i]=vizinho;
        }
    }
}
```

Figura 13 - Função `recristalizacao_hibrido`

Análise dos Resultados Obtidos

Resultados da Pesquisa Local

Para o primeiro Método, decidimos usar como já referido a Recristalização, uma vez que permite variar mais parâmetros para realizar mais testes.

Durante as experiências, fomos variando o temperatura mínima (tmin), a temperatura máxima (tmax) e a frequência de arrefecimento (fa) e o número de interações.

Verificamos no caso de aceitarmos valores com Custo Igual os melhores valores foram encontrados foi quando a temperatura mínima tinha o seu menor valor e a temperatura máxima tinha o seu valor medio e alto.

1 Vizinhaça, Custo Igual - 1000 Iteracoes					
Valores Estáticos		Valores não Estáticos		Melhor Custo	MBF
tmin	0,1	fa	0,1	52	131,46
Tmax	20	fa	0,5	54	96,06
		fa	0,8	45	70,82
Valores Estáticos		Valores não Estáticos		Melhor Custo	MBF
tmin	0,1	tmax	20	54	96,06
fa	0,5	tmax	50	45	68,35
		tmax	70	45	69,44
Valores Estáticos		Valores não Estáticos		Melhor Custo	MBF
tmax	50	tmin	0,1	45	68,35
fa	0,5	tmin	0,5	45	76,06
		tmin	1	45	85,02

Figura 14 - Custo Igual

Em relação ao caso de aceitarmos valores com o Custo Menor, encontramos os melhores valores quando a temperatura mínima, a temperatura máxima e a frequência de arrefecimento se encontra no seu valor mais alto.

2 Vizinhaça, Custo Menor - 3000 Iteracoes					
Valores Estáticos		Valores não Estáticos		Melhor Custo	MBF
tmin	0,1	fa	0,1	87	135,58
Tmax	20	fa	0,5	56	109,38
		fa	0,8	52	87,26
Valores Estáticos		Valores não Estáticos		Melhor Custo	MBF
tmin	0,1	tmax	20	56	109,38
fa	0,5	tmax	50	56	110,44
		tmax	70	55	111,08
Valores Estáticos		Valores não Estáticos		Melhor Custo	MBF
tmax	50	tmin	0,1	56	110,44
fa	0,5	tmin	0,5	57	118,58
		tmin	1	61	121,8

Figura 15 - Custo Menor

Ficamos surpresos, quando o usamos a primeira vizinhança obtemos melhores resultados, no entanto pensávamos que iria ser ao contrário.

Algo que não nos surpreendeu foi os valores com o custo igual serem melhores.

Resultados do Algoritmo Híbrido

Para o segundo Método, optamos por fazer três experiências ao longo dos ficheiros. No primeiro, usamos a Avaliação Penalizada, o Tournament, o Crossover e o Mutation.

Durantes estas experiências notamos que os melhores resultados acontecem quando o PopSize se encontra no seu valor máximo e a percentagem de reprodução e a percentagem de mutação estão ambos nos seus valores médios.

Experiencia 1 - EVP_T_C_M					
Valores Estáticos		Valores não Estáticos		Melhor Custo	MBF
Popsiz	100	Prec	0,1	124,27	167
Pmut	0,01	Prec	0,5	118,77	165
		Prec	0,7	118,33	148
Valores Estáticos		Valores não Estáticos		Melhor Custo	MBF
Popsiz	100	Pmut	0,001	159,2	274
Prec	0,5	Pmut	0,01	118,77	165
		Pmut	0,1	105,27	133
Valores Estáticos		Valores não Estáticos		Melhor Custo	MBF
Prec	0,5	Popsiz	100	118,77	165
Pmut	0,01	Popsiz	1000	114,07	146
		Popsiz	1500	105,17	131

Figura 16 - 1ª Experiência Evolutivo

Na segunda, usamos a Avaliação Penalizada, o Tournament, o Crossover Uniforme e o Mutation.Trade.

Durante estas reparamos que os melhores resultados aparecem quando o PopSize se encontra no valor mínimo, a percentagem de reprodução no valor médio e percentagem de mutação no seu valor máximo.

Experiencia 2 - EVP_T_Cu_Mt					
Valores Estáticos		Valores não Estáticos		Melhor Custo	MBF
Popsiz	100	Prec	0,1	117,03	173
Pmut	0,01	Prec	0,5	117,13	148
		Prec	0,7	121,37	154
Valores Estáticos		Valores não Estáticos		Melhor Custo	MBF
Popsiz	100	Pmut	0,001	149,93	220
Prec	0,5	Pmut	0,01	117,13	148
		Pmut	0,1	103,13	129
Valores Estáticos		Valores não Estáticos		Melhor Custo	MBF
Prec	0,5	Popsiz	100	117,13	148
Pmut	0,01	Popsiz	1000	108,6	135
		Popsiz	1500	103,63	138

Figura 17 – 2ª Experiência Evolutivo

Na terceira, usamos a Avaliação Reparada, o Tournament, o Crossover e o Mutation.

Durantes estas experiências notamos que os melhores resultados acontecem quando o PopSize se encontra no seu valor máximo e a percentagem de reprodução e a percentagem de mutação estão ambos nos seus valores médios.

Experiencia 3 - EVR_T_C_M					
Valores Estáticos		Valores não Estáticos		Melhor Custo	MBF
Popsiz	100	Prec	0,1	89	77,73
Pmut	0,01	Prec	0,5	150	128,57
		Prec	0,7	150	127,67
Valores Estáticos		Valores não Estáticos		Melhor Custo	MBF
Popsiz	100	Pmut	0,001	162	129,27
Prec	0,5	Pmut	0,01	150	128,57
		Pmut	0,1	99	82,9
Valores Estáticos		Valores não Estáticos		Melhor Custo	MBF
Prec	0,5	Popsiz	100	150	128,57
Pmut	0,01	Popsiz	1000	146	130,9
		Popsiz	1500	156	127,5

Figura 18 – 3ª Experiência Evolutivo

Estamos a espera que ao longo dos testes a 3ª Experiência, o contraste em relação à Avaliação Penalizada e Reparada era bem notáveis

Resultados do Algoritmo Híbrido

Para o terceiro Método, como foi ensinado nas aulas práticas, era possível colocar este método em 3 situações, mas havia uma grande diferença a nível de performance para os testes, logo decidimos colocar na primeira para a uma experiência e na primeira e terceira para a última experiência.

Na primeira, usamos a Avaliação Reparada, o Tournament, o Crossover e o Mutation.

Durantes estes testes, reparamos que os melhores resultados acontecem, independente dos valores que íamos mudando.

Experiencia 1 - Híbrido 1ª Abordagem					
Valores Estáticos		Valores não Estáticos		Melhor Custo	MBF
Popsiz	100	Prec	0,1	52	50,57
Pmut	0,01	Prec	0,5	55	50,23
		Prec	0,7	55	51
Valores Estáticos		Valores não Estáticos		Melhor Custo	MBF
Popsiz	100	Pmut	0,001	55	50,53
Prec	0,5	Pmut	0,01	55	50,23
		Pmut	0,1	54	50,73
Valores Estáticos		Valores não Estáticos		Melhor Custo	MBF
Prec	0,5	Popsiz	100	55	50,23
Pmut	0,01	Popsiz	1000	54	50,3
		Popsiz	1500	52	50,1

Figura 19 - 1ª Experiência Híbrido

No entanto, quando colocamos na primeira e na terceira, reparamos que existe uma mudança e os melhores aparecem, quando o PopSize está no seu valor médio e mais alto, a Percentagem de Mutação se encontra no seu valor médio e mais alto e a Percentagem de Reprodução está no seu valor médio.

Experiencia 2 - Híbrido 1ª,3ª Abordagem					
Valores Estáticos		Valores não Estáticos		Melhor Custo	MBF
Popsiz	100	Prec	0,1	153	123,93
Pmut	0,01	Prec	0,5	152	123,17
		Prec	0,7	141	177,7
Valores Estáticos		Valores não Estáticos		Melhor Custo	MBF
Popsiz	100	Pmut	0,001	201	152,47
Prec	0,5	Pmut	0,01	152	123,17
		Pmut	0,1	123	104,37
Valores Estáticos		Valores não Estáticos		Melhor Custo	MBF
Prec	0,5	Popsiz	100	152	123,17
Pmut	0,01	Popsiz	1000	139	114,07
		Popsiz	1500	127	109,63

Figura 20 - 2ª Experiência Híbrido

Ficamos surpresos quando a usar só a primeira abordagem do Híbrido obtivemos melhores resultados, em vez de usar a segunda abordagem. No entanto já estávamos a espera que estes testes mostrariam uns valores bons, em relação ao resto, porque o híbrido, refina os valores ao longo da execução

Conclusão

Com base na descrição do trabalho realizado na cadeira de Introdução à Inteligência Artificial (IIA), o estudo visava resolver um Problema de Otimização por meio da concepção, implementação e teste de métodos para encontrar soluções de custo mínimo.

Dividido em dois componentes, o primeiro focou na criação e implementação de funções para posterior teste, enquanto o segundo se concentrou na realização e análise dos resultados.

O componente de criação/implementação consistiu na criação de várias funções destinadas a serem usadas nos testes. O projeto foi estruturado em três partes principais: funções para o Algoritmo da Pesquisa Local, Algoritmo Evolutivo e Algoritmo do Híbrido. Para avaliação, foram realizados pelo menos dez testes para cada variação de valores.

Através dessas etapas, o trabalho proporcionou não apenas a implementação prática dos algoritmos estudados, mas também a oportunidade de testá-los e analisar seu desempenho em relação ao problema de otimização proposto. Os resultados obtidos desses testes forneceram insights valiosos sobre a eficácia e eficiência dos diferentes métodos aplicados, contribuindo para uma compreensão mais aprofundada das abordagens de Inteligência Artificial em cenários de otimização de custos.